

Curs 8: Simularea variabilelor aleatoare

Conf.dr. Maria Jivulescu

Departamentul de Matematică
UPT



Metode de simulare a variabilelor aleatoare:

- Distribuția unif. continuă;
- Distribuția unif. discretă;
- Distribuția discretă neuniformă;
- Distribuția Bernoulli;
- Distribuția Binomială;
- Distribuția geometrică;
- Distribuții continue care au funcția de repartiție inversabilă prin metoda inversării;

A simula o variabilă aleatoare discretă X , presupune a genera independent, conform unui algoritm, un șir de numere y_1, y_2, \dots, y_N , care să aibă particularitățile unor valori de observație asupra variabilei.

Mai precis: dacă variabila X are distribuția de probabilitate:

$$X = \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ p_1 & p_2 & \dots & p_n \end{pmatrix}$$

atunci distribuția experimentală a datelor generate trebuie să fie foarte apropiată de distribuția teoretică a variabilei X :

dacă nr_k -numărul valorilor generate, egale cu x_k , $k \in \{1, n\}$, atunci $\frac{nr_k}{N}$ trebuie să fie apropiat de p_k

https:

[//www.randomservices.org/random/apps/SpecialSimulation.html](https://www.randomservices.org/random/apps/SpecialSimulation.html)

Cum se simulează o v.a.?

Vom prezentăm pseudocodul pentru o funcție ce returnează **o singură valoare de observație simulată**.

- Această valoare se obține printr-o **transformare sau mai multe, aplicată unei valori u presupusă a fi returnată de un generator de numere pseudo-aleatoare uniform distribuite pe $[0, 1)^1$** .
- Apelul acestui generator îl simbolizăm prin `urand()` (nume generic pentru simulatorul unei variabile aleatoare $U \sim \text{Unif}[0, 1)$.)

$u = \text{urand}() \xrightarrow{\text{Transformare}} x$

De ce folosim $U \sim \text{Unif}[0, 1)$?

¹detalii în Material suplimentar Cap II

Reamintim: dacă $U \sim \text{Unif}[0, 1)$, atunci $(a, b] \subset [0, 1)$,

$$P(U \in (a, b]) = b - a$$

Exemplu: Dacă A — eveniment $P(A) = 0.65$ și $B = \complement A$, $P(B) = 0.35$, atunci putem simula producerea unuia din cele două evenimente astfel:

- apelăm generatorul `urand()`:
`u=urand();`
- Dacă $u < 0.65$, spunem că s-a produs evenimentul ($U < 0.65$),
 $P(U < 0.65) = P(U \in [0, 0.65)) = 0.65$.
 A are aceeași probabilitate de realizare, deci putem considera că s-a produs evenimentul A .
- Dacă $u \in [0.65, 1)$, atunci s-a produs evenimentul ($U \in [0.65, 1)$),
 $P(U \in [0.65, 1)) = 1 - 0.65 = 0.35$.
Deci, în acest caz putem considera că s-a produs evenimentul B .

Observație: Se utilizează la algoritmi randomizați

http://en.wikipedia.org/wiki/Randomized_algorithm.

Propoziție

Dacă $U \sim \text{Unif}[0,1)$ v.a. uniform distribuită pe $[0,1)$, iar n este număr întreg, $n > 1$, atunci

$$X = [nU]$$

o variabilă aleatoare discretă ce are distribuția uniformă pe mulțimea

$$\{0, 1, 2, \dots, n-1\}, \text{ adică } X = \begin{pmatrix} 0 & 1 & \dots & n-1 \\ \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \end{pmatrix}$$

Demonstrație: se bazează pe

- U ia valori în $[0, 1)$, variabila nU ia valori în $[0, n)$ și $[nU] \in \{0, 1, \dots, n-1\}$.

$$P(X = k) = P([nU] = k) = P(k \leq nU < k+1)$$

$$= P\left(\frac{k}{n} \leq U < \frac{k+1}{n}\right) = P\left(U \in \left[\frac{k}{n}, \frac{k+1}{n}\right)\right) = \frac{k+1}{n} - \frac{k}{n} = \frac{1}{n}$$

```
1 Function SimDiscretU(n)
2 u=rand();
3 k=int(n*u);
4 return k;
5 end.
```

Observație: Înlocuind `return k;` cu `return x_k ;` se returnează o valoare de observație asupra unei variabile aleatoare discrete, uniform distribuită pe o mulțime $\{x_0, x_1, \dots, x_{n-1}\}$, adică asupra variabilei aleatoare:

$$X = \begin{pmatrix} x_0 & x_1 & \dots & x_{n-1} \\ \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \end{pmatrix}$$

Observație: Simularea acestei variabile aleatoare este echivalentă cu simularea experimentului de extragere la întâmplare a unui element (obiect) din lista x_0, x_1, \dots, x_{n-1} și returnarea lui în "recipientul" din care a fost scos. La întâmplare înseamnă că fiecare element are aceeași șansă de a fi extras, adică probabilitatea $1/n$.

Algoritm ce extrage un număr la întâmplare din mulțimea de numere întregi $\{m, m+1, \dots, n\}$, $m < n$.

- Mulțimea conține $N = n - m + 1$ elemente.
- Un număr selectat la întâmplare este o valoare de observație asupra variabilei aleatoare:

$$X = \begin{pmatrix} m & m+1 & \dots & n \\ \frac{1}{n-m+1} & \frac{1}{n-m+1} & \dots & \frac{1}{n-m+1} \end{pmatrix}.$$

```

1 Function randint(m,n)
2 u=urand();
3 k=int((n-m+1)*u));//k in {0, 1, 2, ..., n - m}
4 return k+m;
5 end.
```

Aplicație: Generarea unei permutari aleatoare²


²a se vedea notițe curs 8.

Fie X o v.a. discretă cu valorile ordonate, adică $x_0 < x_1 < \dots < x_{n-1}$.

$$X = \begin{pmatrix} x_0 & x_1 & \dots & x_{n-1} \\ p_0 & p_1 & \dots & p_{n-1} \end{pmatrix}, \quad \sum_{k=0}^{n-1} p_k = 1$$

- divizăm intervalul $[0, 1)$, prin punctele

$$F_0 = p_0, \quad F_1 = p_0 + p_1, \dots, F_k = p_0 + p_1 + \dots + p_k, \dots, \\ F_{n-1} = 1$$



- Avem:

$$P(U \in (F_{k-1}, F_k]) = F_k - F_{k-1} \text{ lung.interv.} = p_k = P(X = x_k)$$

(am considerat $F_{-1} = 0$).

```
1 Function SimDiscret (x, p, n)//x, p sunt tablouri de n elemente
2 k = 0;
3 F = p0;
4 u=rand();
5 while (u > F){
6     k = k + 1;
7     F = F + pk;
8 }
9 return xk;
10 end.
```

Obs.: metodă recomand. pentru v.a. cu un număr redus de valori; Altfel, se recomand. calculul $F_k = p_0 + p_1 + \dots + p_k$, $k \in \{0, n-1\}$ și căutarea binară a interv. $(F_{k-1}, F_k]$ în care cade $u \in [0, 1)$, dat de `urand()`.

Distribuția Bernoulli $X = \begin{pmatrix} 1 & 0 \\ p & 1-p \end{pmatrix}$ se simulează când avem de făcut o alegere dintre două alternative, codificate cu 1 și 0.



- se generează $u \in [0, 1)$, apelând $u = \text{urand}()$;
- Dacă $u \leq p$, atunci s-a produs evenimentul ($U \leq p$), $P(U \leq p) = P(0 \leq U \leq p) = p - 0 = p$ (aceeași probab. ca ($X = 1$)). Putem presupune că s-a produs acesta și alegem 1.
- Dacă însă $u > p$, atunci facem alegerea codificată de 0.

```
1 Function Bernoulli(p);  
2 u=urand();  
3 if (u < p) return 1;  
4 else return 0;  
5 end
```

Fie $X \sim \text{Bin}(n, p)$ cu $X = \begin{pmatrix} 0 & 1 & \dots & k & \dots & n \\ Pr_0 & Pr_1 & \dots & Pr_k & \dots & Pr_n \end{pmatrix}$

Obs.: se simulează conform algoritmului prezentat mai sus, singura problemă fiind calculul probabilităților $Pr_k = P(X = k) = C_n^k p^k (1 - p)^{n-k}$ și a sumelor $F_k = Pr_0 + Pr_1 + \dots + Pr_k$, $k \in \{0, n\}$.

Folosind $C_n^{k+1} = C_n^k \frac{n-k}{k+1}$, avem

$$Pr_{k+1} = P(X = k + 1) = C_n^{k+1} p^{k+1} (1 - p)^{n-k-1} = \frac{n-k}{k+1} \frac{p}{1-p} P(X = k)$$

Notând cu $c = \frac{p}{1-p}$, obținem

$$Pr_{k+1} = \frac{n-k}{k+1} c Pr_k, \quad Pr_0 = (1-p)^n$$

```
1 FunctionBin( $n, p$ )
2  $k = 0$ ;
3  $c = p/(1 - p)$ ;
4  $pr = (1 - p)^n$ ;
5  $F = pr$ ;
6  $u = \text{urand}()$ ;
7 while ( $u > F$ ) {
8      $pr = (c * (n - k) / (k + 1)) * pr$ 
9      $F = F + pr$ ;
10     $k = k + 1$ ;
11 }
12 return  $k$ ;
13 end.
```

Obs.: Dacă parametrul n este foarte mare, atunci căutarea liniară nu este performantă. În acest caz se recomandă precalcularea $Pr_k = P(X = k)$, $k \in \{0, n\}$ și a sumelor $F_j = \sum_{i=0}^k pr_i$ și folosirea căutării binare.

Fie X o variabilă aleatoare ce are distribuția geometrică de parametru

$$p \in (0, 1), X \sim \text{Geom}(p), X = \binom{k}{p(1-p)^{k-1}}, \quad k \in \mathbb{N} \setminus \{0\}$$

Metoda directă de simulare= variabilă geometrică este asociată unui experiment Bernoulli:

```
1 FunctionGeom1(p)
2 k=0; // k contorul pentru incercarile Bernoulli
3 do {
4     u=urand()
5     k=k+1;
5     } while(u > p);
6 return k
7 end
```

Obs.:

- Se execută blocul de instrucțiuni din bucla do-while atâta timp cât încercările sunt un eșec.
- La primul succes returnează numărul încercării respective.
- Dacă probabilitatea succesului p este mică numărul mediu de încercări până la primul succes este mare pentru că $M(X) = 1/p$ și în acest caz algoritmul Geom1 este ineficient.

Propoziție

Dacă $p \in (0, 1)$ și $U \sim \text{Unif}[0, 1)$, atunci variabila aleatoare:

$$X = \left\lceil \frac{\ln(1 - U)}{\ln(1 - p)} \right\rceil + 1$$

are distribuția geometrică de parametru p .

Deci, pentru variabila aleatoare $X \sim \text{Geom}(p)$, evenimentul $(X = k)$ are aceeași probabilitate ca evenimentul $\left(\left\lceil \frac{\ln(1-U)}{\ln(1-p)} \right\rceil + 1 = k\right)$,

```
1 FunctionGeom2(p)
2 u=urand();
3 return int(log(1 - u)/log(1 - p)) + 1;
4 end.
```


Pauză!

Dupa pauză... Simularea variabilelor aleatoare continue

Metoda inversării de simulare a variabilelor aleatoare continue se aplică pentru **variabilele ce au funcția de repartiție inversabilă**.

Funcția de repartiție a unei variabile aleatoare continue, X , având densitatea de probabilitate f_X este funcția $F_X : \mathbb{R} \rightarrow \mathbb{R}$,

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f(x) dx$$

- o funcție continuă;
- nedescrescătoare, adică dacă $x_1 < x_2$, atunci $F_X(x_1) \leq F_X(x_2)$
- $\lim_{x \rightarrow -\infty} F_X(x) = 0$, iar $\lim_{x \rightarrow \infty} F_X(x) = 1$.

Funcția de repartiție F_U a unei variabile aleatoare, $U \sim \text{Unif}[0, 1]$:

$$F_U(x) = \begin{cases} 0 & x < 0 \\ x & x \in [0, 1] \\ 1 & x \geq 1 \end{cases}$$

Obs.:

- F_U restricționată la intervalul $[0, 1]$ este funct. identică: $F_U(x) = x$.
- Prin transformări inversabile, $h : \mathbb{R} \rightarrow \mathbb{R}$, adecvat alese, un șir (u_n) de numere uniform distribuite pe $[0, 1]$ poate fi transformat într-un șir $(x_n = h(u_n))$ ale cărui elemente sunt valori de observație asupra unei variabile aleatoare $X = h(U)$, cu $U \sim \text{Unif}[0, 1]$.
- Cea mai simplă metodă de transformare a șirului (u_n) este **metoda inversării**.

- se aplică pentru a genera numere pseudo-aleatoare ca valori de observație asupra unei variabile aleatoare X , ce are funcția de repartiție inversabilă.
- dacă F_X este strict crescătoare, atunci ea este inversabilă.
- Pentru orice $u \in (0, 1)$, $F_X^{-1}(u) \in \mathbb{R}$.
- u ca valoare de observație asupra unei variabile aleatoare $U \sim \text{Unif}[0,1)$, x este valoare de observație asupra variabilei $F_X^{-1}(U)$.
- determinăm distribuția de probabilitate a variabilei $Y = F_X^{-1}(U)$:

Propoziție

Fie $U \sim [0, 1)$ și F_X o funcție de repartiție strict crescătoare și continuă pe intervalul de lungime minimă din \mathbb{R} , pe care variabila aleatoare X ia valori cu probabilitatea 1.

Atunci variabila aleatoare

$$Y = F_X^{-1}(U)$$

are aceeași funcție de repartiție ca și variabila X , adică Y și X sunt identic distribuite și nu se disting din punct de vedere probabilist.

Demo: $U \sim \text{Unif}[0, 1) \Rightarrow F_U(x) = x, \quad x \in [0, 1)$ și $F_U(x) = 0$, în rest.

Vom determina funcția de repartiție G_Y a variabilei $Y = F_X^{-1}(U)$:

$$G_Y(x) = P(Y \leq x) = P(F_X^{-1}(U) \leq x) = P(U \leq F_X(x)) = F_U(F_X(x)) = F_X(x)$$


Prin urmare $G_Y(x) = F_X(x), \quad \forall x$, adică funcția de repartiție a variabilei aleatoare $Y = F_X^{-1}(U)$ este chiar F_X .

Algoritm de simulare a unei variabile aleatoare X ce are funcția de repartiție F_X inversabilă:

- 1 FunctionMetodaInversarii()
- 2 $u = \text{urand}();$
- 3 $x = F_X^{-1}(u);$
- 4 **return x;**
- 5 end.

Fie

- Funcția de repartiție: $F_X(x) = \begin{cases} 0 & \text{dacă } x < 0 \\ 1 - e^{-x/\theta} & \text{dacă } x \geq 0 \end{cases}$



- F_X este strict crescătoare pe intervalul $[0, \infty)$
- $\forall u \in [0, 1), F^{-1}(u) \in [0, \infty)$.
- O v. a. exponențial distribuită ia valori pozitive cu probabilitatea 1:
 $P(X \geq 0) = 1 - P(X < 0) = 1 - F_X(0) = 1 - 0 = 1$
- prin metoda inversării putem simula X .
- Din $1 - e^{-x/\theta} = u$, avem $x = F^{-1}(u) = -\theta \ln(1 - u)$

```
1 Function SimulExp(theta)
2 u=rand();
3 x = -theta * log(1 - u);
4 return x;
5 end
```

Obs.: Dacă (u_n) , $n = 0, 1, \dots, N$ este un șir de numere pseudo-aleatoare uniform distribuit pe $[0, 1)$, atunci șirul $(1 - u_n)$, este de asemenea uniform distribuit pe $[0, 1)$.

Astfel, în simularea unei variabile aleatoare $X \sim \text{Exp}(\theta)$ putem înlocui pe $1 - u$ cu u .